

Clasificación de polaridad de sentimiento sobre tweets en español

Representación BoW + características léxicas propias — InterTASS-ES 2018

Procesamiento de Lenguaje Natural

Integrantes: Mateo Echeverría González | Juan David López Camargo

1. Problema y datos

El taller de referencia entrega un clasificador base de polaridad de sentimiento sobre el corpus InterTASS-ES 2018, construido con una representación Bag of Words (BoW) y un modelo Softmax. BoW conserva el vocabulario empleado pero descarta el orden, la intensidad expresiva y otras señales propias del lenguaje informal de Twitter (elongaciones, mayúsculas, negación, puntuación repetida, emojis). El objetivo de este trabajo es ampliar el conjunto de características léxicas existente, combinarlas con una representación vectorial de texto y determinar experimentalmente qué algoritmo de clasificación es el más adecuado, justificando cada decisión con evidencia y sin fuga de información (data leakage).

El corpus contiene tweets en español etiquetados en cuatro clases de polaridad: N (negativo), NEU (neutral), NONE (sin opinión) y P (positivo), con 1.008 tweets de entrenamiento y 506 de prueba. La distribución de clases está desbalanceada de forma casi idéntica en ambos conjuntos (N y P dominan sobre NEU y NONE), lo que constituye una característica estructural del problema y no un artefacto del particionamiento. Por esta razón, el criterio de evaluación adoptado en todo el trabajo es macro-F1 y no accuracy, ya que este último premiaría un modelo que solo prediga las clases mayoritarias.




Figura 1. Distribución de clases en train y test — el desbalance N/P frente a NEU/NONE es consistente entre ambos conjuntos.

2. Hipótesis de cada característica

2.1 Auditoría de las características existentes (Fase 0)

Antes de añadir características nuevas se auditaron las 29 que entregaba `get_features_lexical()`, verificando para cada una si era constante, si actuaba como proxy de la longitud del texto (correlación con el número de tokens) o si dejaba de activarse por errores de orden en el preprocesamiento. Como resultado, 24 características sobrevivieron sin cambios, 2 se corrigieron directamente en el código (bugs de preprocesamiento que las dejaban en 0% de activación) y 3 se excluyeron por redundancia.

Característica	Veredicto	Decisión
label_hashtag / label_emoji	Constantes en 0 por bugs de preprocesamiento (typo y orden de encoding)	Corregidas en el pipeline
weighted_position / weighted_normalized	Proxies casi perfectos de la longitud del texto ($r \approx 0,72$ y $r \approx 0,98$)	Excluidas
label_word	Correlación $r \approx 0,99$ con el n.º de tokens — redundante con BoW	Excluida
lexical_diversity / adverb_all	Sesgo por longitud ($r \approx -0,81$) o colinealidad exacta con otras 5 columnas	Reemplazada / excluida

2.2 Características léxicas nuevas (Fase 1)

Se incorporaron 4 características nuevas, cada una respaldada por una hipótesis lingüística explícita y verificada para no duplicar señales ya existentes:

Característica	Hipótesis lingüística
lexical_diversity_mattr	El TTR original depende matemáticamente de la longitud del texto; MATTR (ventana móvil) corrige ese sesgo y reemplaza a lexical_diversity.
elongated_words_count	La elongación de caracteres ("buenooo") marca intensidad emocional propia del registro informal de Twitter.
punct_repetition	La repetición de "!"/"?" intensifica la carga emocional, señal que BoW no captura por tratar cada signo como token independiente.

Característica	Hipótesis lingüística
lex_pol_neg	Un conteo crudo de polaridad falla bajo negación ("no me gusta"); esta característica invierte el signo dentro del alcance de la negación, sin duplicar los conteos crudos existentes.

Sobre el corpus completo de entrenamiento, la cobertura de estas características confirma que no son constantes: lex_pol_neg se activa en 26,5% de los tweets, punct_repetition en 4,9% y elongated_words_count en 3,0%. El vector léxico final queda compuesto por 24 características validadas + 4 nuevas = 28 columnas.

3. Diseño experimental

3.1 Representaciones vectoriales (Fase 2)

Se construyeron tres representaciones sobre el mismo pipeline de preprocesamiento, unidas mediante ColumnTransformer: (E0) BoW solo, con n-gramas de palabra 1-3; (E1) características léxicas solas (28 columnas); y (E2) la unión de ambas.

- **E0 — BoW** solo (26.057 dimensiones) aporta vocabulario específico, es decir, qué palabras exactas aparecen, pero pierde intensidad y tono: no distingue "bien" de "BIEN!!!" ni resuelve la negación.
- **E1 — Léxico** solo (28 dimensiones) aporta señales de forma e intensidad —negación resuelta, elongación, puntuación—, pero pierde el vocabulario concreto, ya que no identifica qué palabras específicas se usaron.
- **E2 — Unión** (26.085 dimensiones) combina lo mejor de ambas representaciones, a costa de una mayor dimensionalidad (riesgo de sobreajuste) y de mezclar escalas distintas.

El escalado del bloque léxico se justificó estadística y empíricamente: punct_repetition y elongated_words son conteos raros (sesgo > 6, entre 95% y 97% de ceros). StandardScaler centra con la media y convierte el valor 0 —el caso típico— en un número distinto de cero, borrando la señal de "esto no ocurrió"; RobustScaler usa mediana e IQR y preserva 0→0. Esto se validó entrenando un modelo real: RobustScaler obtuvo macro-F1 = 0,3662 en validación cruzada frente a 0,3589 de StandardScaler, confirmando la elección con evidencia y no solo con estadística descriptiva.

3.2 Selección del algoritmo de clasificación (Fase 3)

Se compararon 4 familias de clasificadores sobre E2 —Softmax (regresión logística), SVM lineal, Naive Bayes multinomial y Random Forest— con hiperparámetros ajustados vía GridSearchCV en validación cruzada estratificada de 5 folds, balanceo de clases aplicado únicamente dentro de cada fold (nunca antes de dividir los datos) y selección por macro-F1. Se discutió explícitamente la compatibilidad entre algoritmo y representación:

- Softmax y SVM lineal: sin problemas en alta dimensión dispersa; se usó RobustScaler.
- Naive Bayes multinomial: incompatible por diseño con valores negativos (RobustScaler y las columnas skew_word/kur_word pueden producirlos); se resolvió usando MinMaxScaler, que por construcción mapea siempre a [0,1].
- Random Forest: el enunciado advierte que los árboles rinden distinto en espacios muy dispersos; se verificó con evidencia real sobre 26.085 dimensiones y 1.008 filas.

El baseline real del taller (protocolo honesto, sin fuga) es macro-F1 = 0,3506 en test; el 80% que reporta el propio taller en su validación promedio está inflado porque el oversampling se aplicaba sobre todo el train antes de particionar en folds.

4. Resultados

Modelo	macro-F1 (CV, 5 folds)
Softmax	0,3721 (± 0,0172)
SVM lineal	0,3783 (± 0,0213)
Naive Bayes multinomial	0,3962 (± 0,0418) — ganador
Random Forest	0,3175 (± 0,0214) — último lugar

Naive Bayes fue evaluado una única vez sobre el conjunto de test, con refit explícito sobre todo el train: macro-F1 = 0,4157, con intervalo de confianza 95% por bootstrap de [0,3698, 0,4584]. El baseline (0,3506) queda fuera de ese intervalo, lo que indica una mejora sólida y no atribuible al ruido entre folds.




Figura 2. Comparación de clasificadores sobre E2.




Figura 3. Resultado final en test vs. baseline (IC 95%).

4.1 Métricas por clase y matriz de confusión

Clase	Precisión	Recall	F1	Soporte
N	0,624	0,644	0,634	219
NEU	0,200	0,275	0,232	69
NONE	0,286	0,258	0,271	62
P	0,581	0,481	0,526	156




Figura 4. Matriz de confusión normalizada por fila del modelo final (Naive Bayes multinomial).

NEU y NONE son las clases más débiles (recall 0,275 y 0,258): ambas representan "ausencia de opinión fuerte", una distinción sutil incluso para anotadores humanos, para la que el vector léxico carece de señales fuertes. P se confunde con N en 37 de 156 casos, principalmente por vocabulario positivo en formas flexivas que el léxico (~25 palabras por polaridad) no reconoce. N es la clase más fuerte (recall 0,644) gracias a mayor soporte y vocabulario negativo más directo.

5. Ablación: aporte de cada característica nueva

Se midió cuánto aporta cada característica nueva al macro-F1 del modelo final (Naive Bayes), removiéndola individualmente y comparando contra el modelo completo (macro-F1 = 0,3962).

Característica	Aporte individual (Δ macro-F1)
mattr	+0,0007
elongated_words	+0,0000
punct_repetition	-0,0007
lex_pol_neg	+0,0031 (la de mayor aporte)
Aporte total de las 4 nuevas	+0,0017

El aporte individual es pequeño (todas por debajo de 0,004, dentro del ruido de $\pm 0,04$ entre folds). Esto no indica un mal diseño de las características, sino que, para Naive Bayes específicamente, 28 columnas léxicas compiten contra 26.057 de BoW, y el suavizado de Laplace atenúa señales raras (elongated_words y punct_repetition, activas en solo 3-5% de los tweets). lex_pol_neg es la que más aporta, consistente con su mayor cobertura (26,5%).

6. Análisis de errores

Se analizaron 10 tweets reales mal clasificados, agrupados por tipo de error:




Figura 5. Aporte individual de cada característica nueva.




Figura 6. Tipos de error identificados (muestra de 10 errores reales).

- Léxico incompleto — forma flexiva no cubierta (4 casos): p. ej. "encantado" no coincide con "encanta"/"encantar" por no haber lematización; "enamora", "estupendo" y "adorable" no están en el léxico manual de ~25 palabras por polaridad.
- Doble negación / negación sobre palabra ausente (1 caso): "No me quejo" — "quejo" no está en el léxico, por lo que la negación no tiene nada que invertir.
- Ironía y humor no capturados (2 casos): tono sarcástico o festivo que invierte el sentido literal ("no estáis invitados" en contexto de celebración), fenómeno pragmático que ninguna característica léxica captura.
- Confusión entre clases débiles NEU vs. NONE (1 caso): preguntas retóricas sin opinión clara, límite difuso incluso para anotadores humanos.
- Dependencia del dominio (2 casos): descripciones neutras (videojuegos, ocupación profesional) clasificadas como polares porque BoW capta coincidencias de vocabulario sin relación con opinión real.

7. Limitaciones

- Desbalance de clases: N/P dominan sobre NEU/NONE. El oversampling dentro de cada fold corrige el sesgo metodológico del entrenamiento, pero no la dificultad estructural del problema — NEU y NONE siguen con el peor recall incluso después de aplicarlo.
- Ironía y humor: al menos 2 de los 10 errores analizados muestran tono sarcástico que invierte el sentido literal — fenómeno pragmático, no lexicográfico.
- Variación dialectal: el corpus es monolingüe (España); no se evaluó con las variantes de Perú o Costa Rica de InterTASS 2018.
- Dependencia del léxico: el léxico de polaridad manual (~25 palabras por clase) no cubre variantes flexivas — 4 de los 10 errores documentan exactamente este problema.
- Dependencia del dominio: contenido puramente descriptivo se clasifica erróneamente como polar cuando BoW capta coincidencias de vocabulario sin relación con opinión real.
- Evaluación en Dev., no en Test oficial: el conjunto de "test" propio (506 tweets) coincide en tamaño y distribución con el conjunto oficial de Desarrollo de InterTASS-ES 2018, no con el Test oficial (1.899 tweets); la comparación con la referencia oficial es orientativa, no exacta sobre el mismo conjunto.

Frente a la referencia oficial (CEUR-WS, Vol. 2172), el modelo final supera el baseline del taller en +0,065 puntos de macro-F1 y se ubica en el extremo inferior del rango de sistemas oficiales de TASS 2018 (0,097–0,503) — un resultado razonable para un sistema clásico BoW + léxico, sin deep learning ni embeddings preentrenados.

8. Conclusión sobre el algoritmo elegido

El algoritmo elegido es Naive Bayes multinomial, sobre la representación unida E2 (BoW + 28 características léxicas), con MinMaxScaler en el bloque léxico para resolver su incompatibilidad con valores no negativos.

Métrica	Valor
macro-F1 en CV (selección)	0,3962
macro-F1 en test (evaluación única)	0,4157
IC 95% bootstrap	[0,3698, 0,4584]
Baseline real del taller	0,3506 (fuera del IC — mejora sólida, no ruido)
Mejor sistema oficial TASS 2018	0,503 (evaluado en otro conjunto de test)

De las 4 familias comparadas con GridSearchCV en validación cruzada estratificada, Naive Bayes obtuvo el mejor macro-F1 pese a ser la única con una incompatibilidad real por resolver (escalado no negativo) — un resultado no trivial. El trabajo recorrió las cinco fases exigidas: auditoría de características existentes, diseño de nuevas características justificadas lingüísticamente, comparación de representaciones con escalador validado empíricamente, selección de algoritmo sin fuga de información, y un análisis crítico con ablación, matriz de confusión, errores reales categorizados y limitaciones respaldadas con evidencia propia.