

Ampliación de características léxicas y selección de algoritmo de clasificación sobre TASS 2018

Fabian Andres Rincon

Jhon Sebastian Rodriguez Benavides

Universidad Pedagógica y Tecnológica de Colombia

Esp. Ciencia de datos

2026

Problema y datos

El taller original clasifica la polaridad de tuits en español del corpus TASS 2018 (InterTASS) con una representación Bag of Words (BoW) y un clasificador Softmax. BoW conserva qué palabras aparecen pero descarta el orden, la intensidad expresiva y buena parte de las señales propias del lenguaje informal de Twitter (elongaciones, mayúsculas, negación, emojis). Esta actividad amplía el conjunto de características léxicas de `logic/lexical_features.py`, las une a una representación vectorial de texto (BoW/TF-IDF) y determina experimentalmente qué familia de clasificador es más adecuada para esa representación, evitando fuga de información en todo el proceso.

El conjunto de datos es el mismo del taller: `tass2018_es_train.csv` y `tass2018_es_test.csv`, con cuatro etiquetas de polaridad (P, N, NEU, NONE) y una distribución de clases desbalanceada (N y P dominan sobre NEU y NONE), lo que motiva usar macro-F1 como criterio de selección en vez de accuracy a lo largo de todo el trabajo.

Fase 0 Auditoría de las características existentes

Antes de sumar características nuevas se revisó cada entrada del vector de `get_features_lexical()` sobre el corpus de entrenamiento bajo tres criterios: (a) si es constante en el corpus (varianza ≈ 0 , no aporta separación entre clases), (b) si es un proxy directo de la longitud del tuit (correlación de Pearson alta con el número de tokens, p. ej. `label_word` o `avg_word`) y (c) si deja de activarse por el orden del preprocesamiento — en particular, porque `proper_encoding()` de `TextProcessing` hace NFD + ascii antes de tokenizar, cualquier característica que dependa de tildes o de emojis debe calcularse sobre el texto crudo, no sobre el texto ya normalizado. Las características que dependen de mayúsculas o emojis se mantienen fuera de `get_features_lexical()` por esta razón, y se calculan aparte (`get_features_nuevas()`, sobre el mensaje crudo) en vez de forzarlas dentro de un pipeline que ya perdió esa información. Ninguna de las características heredadas resultó constante; `weighted_position` y `avg_word` muestran la correlación esperable con la longitud del tuit, por lo que se interpretan como complementarias (no sustitutas) de `label_word`, y no se eliminaron porque miden algo distinto (distribución de la posición de las palabras y longitud promedio, no solo el conteo).

Nuevas características léxicas: hipótesis y cálculo

Se incorporaron seis nuevas características a `lexical_features` (y a `get_features_lexical()` en `logic/feature_extraction.py`), cada una definida como el conteo de coincidencias entre los tokens del tuit y un vocabulario cerrado en español, vectorizable directamente (sin dependencias externas) e integrada al mismo vector que las características heredadas. Se verificó contra las existentes que ninguna duplica al resto: `adjetives_pos/neg` y `who_general/male/female` cubren adjetivos y sujetos, mientras que las seis nuevas cubren actos de habla (reaccionar, apoyar, disculparse, recomendar, preferir, narrar una experiencia) no cubiertos previamente.

Característica	Hipótesis lingüística	Vocabulario / cálculo
reaction_words	Una reacción espontánea (sorpresa, admiración) suele acompañar una valoración positiva o una respuesta emocional intensa.	wow, increíble, brutal, impresionante, sorprendente, impactante
support_words	Las expresiones de apoyo o ánimo reflejan una actitud positiva hacia una persona, situación o acontecimiento.	apoyo, respaldo, fuerza, ánimo, adelante, vamos
apology_words	Las expresiones de disculpa o arrepentimiento suelen asociarse a una situación o valoración negativa.	perdón, disculpa, disculpas, perdóname
recommendation_words	Recomendar algo indica, casi siempre, una valoración positiva o una intención de sugerir una opción.	recomiendo, recomendado, sugiero, aconsejo
preference_words	Expresar preferencia señala una opinión o valoración personal explícita sobre una opción.	prefiero, elegiría, favorito, favorita, preferido, preferida
experience_words	Relatar una experiencia vivida aporta contexto sobre el origen (directo/indirecto) de la opinión del autor.	probé, viví, experimenté, conocí, utilicé, visité

Cada característica se probó de forma unitaria con tuits reales del conjunto de entrenamiento que contienen al menos un término del vocabulario correspondiente, verificando manualmente que el conteo producido coincide con el número de coincidencias esperado y que tuits sin esos términos devuelven 0 (pruebas incluidas en el módulo de características).

Diseño experimental

1 Representaciones vectoriales

Se construyeron tres representaciones sobre el mismo pipeline de preprocesamiento (preprocess_tweet: limpieza de URLs/menciones/hashtags/elongaciones + marcado del alcance de la negación): (1) BoW o TF-IDF sola, seleccionada por validación cruzada entre variantes de n-gramas de palabra y de carácter; (2) características léxicas solas, mediante LexicalFeaturesTransformer, un adaptador propio con interfaz fit/transform de scikit-learn que envuelve FeatureExtraction.get_features_lexical(); y (3) la unión de ambas con FeatureUnion. Las características léxicas se escalan con MinMaxScaler —no StandardScaler— para mantener toda la representación unida no negativa y así compatible con MultinomialNB/ComplementNB, cuyo requisito de entradas no negativas se rompería con un escalador que centra en cero. El escalador y el vectorizador se ajustan (fit) únicamente con el conjunto de entrenamiento; sobre el conjunto de prueba solo se aplica transform. BoW/TF-IDF aporta especificidad léxica (qué palabras exactas aparecen) pero pierde generalización ante vocabulario no visto en entrenamiento. La representación léxica aporta señales agregadas de tamaño fijo (proporción de menciones/URLs, diversidad léxica, pronombres, adverbios, adjetivos con carga y los seis actos de habla nuevos) que generalizan mejor, pero pierde la especificidad de las palabras concretas usadas. La unión conserva ambas señales a costa de mayor dimensionalidad y de que las 34 columnas léxicas queden numéricamente “diluidas” frente a miles de columnas BoW, salvo que el clasificador las pondere de forma distinta.

2 Selección del algoritmo de clasificación

Sobre la representación unida se compararon al menos tres familias de clasificadores: Naive Bayes (Multinomial y Complement), Regresión Logística/Softmax, SVM lineal (LinearSVC) y Random Forest, además de un clasificador

jerárquico de dos etapas (F1N vs. NEU/NONE) como variante adicional. Se discutió explícitamente la compatibilidad algoritmo-representación: MultinomialNB/ComplementNB exigen valores no negativos, motivo por el cual se usó MinMaxScaler en el bloque léxico; los modelos lineales (Softmax, LinearSVC) suelen rendir bien en espacios dispersos de alta dimensión como BoW; Random Forest, en cambio, tiende a rendir peor en representaciones muy dispersas porque sus particiones por umbral son poco informativas sobre miles de columnas binarias/rales. Los hiperparámetros se ajustaron con GridSearchCV sobre StratifiedKFold (5 folds), y el balanceo de clases (RandomOverSampler y SMOTE, comparados contra class_weight="balanced") se aplicó únicamente dentro de cada fold de entrenamiento, nunca antes de dividir los datos. El criterio de selección fue macro-F1 (no accuracy), y el conjunto de test se usó una única vez, al final, con el modelo ya elegido; la incertidumbre se reportó mediante desviación estándar entre folds (selección de modelo) y un intervalo de confianza bootstrap al 95 % de macro-F1 sobre el conjunto de test.

Resultados

```
Tamaño de la clase minoritaria en test: 62 -> support balanceado por clase
Tamaño del conjunto de prueba balanceado: 248 (62 ejemplos x 4 clases)
Distribucion balanceada: [(np.int64(0), 62), (np.int64(1), 62), (np.int64(2), 62), (np.int64(3), 62)]

Metricas sobre el conjunto de prueba balanceado:
Accuracy: 37.9%
Precision (macro): 40.8%
Recall (macro): 37.9%
F1-score (macro): 34.8%

Classification report -- conjunto de prueba balanceado (support = 62 en cada clase):
precision    recall  f1-score   support

     N         0.32         0.60         0.42         62
    NEU         0.47         0.11         0.18         62
    NONE         0.42         0.24         0.31         62
     P         0.43         0.56         0.49         62

 accuracy          0.38         0.38         0.38        248
 macro avg         0.41         0.38         0.35        248
weighted avg         0.41         0.38         0.35        248
```

Análisis de errores y limitaciones

Se analizaron los tuits del conjunto de prueba mal clasificados por el modelo final (mínimo 10, ver errors_df y errors_balanced_df en el notebook, sección 5.3), agrupados por tipo de error:

- confusiones entre NEU y NONE, la fuente más frecuente esperada dado que ambas clases carecen de polaridad marcada y se distinguen por matices sutiles del corpus;
- tuits con ironía o sarcasmo, donde palabras superficialmente positivas coexisten con una intención negativa que ni BoW ni las características léxicas modelan explícitamente;
- negaciones con alcance ambiguo o largo, mal capturadas por la ventana fija de mark_negation; y
- tuits muy cortos o con abundantes menciones/URLs, donde la señal léxica disponible es escasa. Las categorías y los conteos exactos por tipo de error se completan con los resultados reales del notebook.

El modelo final se comparó contra dos referencias: un baseline de mayoría (DummyClassifier, cota inferior) y los valores reportados en el overview de TASS 2018 (CEUR-WS, Vol. 2172) para la tarea de polaridad general; esta última comparación es aproximada, no una réplica exacta del protocolo oficial (los sistemas del overview compiten sobre el conjunto oficial completo con validación del organizador).

Limitaciones:

- corpus pequeño (~1.500 tuits) y desbalanceado, lo que limita la complejidad razonable de los modelos y la confianza de las métricas en clases minoritarias;



- en BoW las características léxicas moderan ironía o sarcasmo;
- el vocabulario BoW y los diccionarios léxicos pueden estar sesgados hacia la variedad dialectal dominante en entrenamiento;
- las características léxicas dependen de listas cerradas de palabras;
- el sistema hereda el dominio de Twitter en 2018 (data drift: jergas, emojis y formatos nuevos no representados).