

Clasificación de sentimiento en tweets en español (TASS 2018): características léxicas e integración con una representación vectorial

Ivan S. Cruz A. y Juan S. Ochoa V. — Procesamiento de Lenguaje Natural

1. Problema y datos:

El baseline del taller (*Bag of Words* + *Softmax*) captura qué palabras aparecen en un tweet, pero descarta buena parte de la señal informal donde vive la polaridad: elongaciones (“*buenooo*”), mayúsculas, signos repetidos, intensificadores, atenuadores y marcadores dialectales. El objetivo de esta actividad fue extender ese baseline con características léxicas propias, integrarlas a una representación vectorial de texto y seleccionar el clasificador más adecuado bajo un protocolo experimental libre de fuga de información.

Trabajamos sobre el corpus *InterTASS-ES 2018*: 1008 tweets de entrenamiento y 506 de evaluación. Este último corresponde a la partición Dev oficial de la competencia y no al test oficial de 1899 tweets, por lo que cualquier comparación con la tabla del overview de TASS es orientativa y no directa. El corpus está desbalanceado ($N = 41\%$, $P = 32\%$, $NEU = 13\%$, $NONE = 14\%$), lo que motivó usar macro-F1 como criterio de selección en lugar de accuracy.

2. Características léxicas nuevas

Aportamos 9 características agrupadas en tres familias, cada una con una hipótesis lingüística explícita y verificada empíricamente sobre el train real:

- **Expresividad (5):** `elongated_count` (alargamiento de letras), `upper_ratio` (proporción de mayúsculas), `exclam_run_max` y `question_run_max` (racha máxima de !/?), `interrobang_count` (?! combinados).
- **Modificadores (2):** `intensifier_count` (“muy”, “súper”, “demasiado”), `attenuator_count` (“algo”, “un poco”, “casi”).
- **Coloquial (2):** `interjection_count` (“ay”, “uf”, “ojalá”), `regionalism_count` (marcadores dialectales).

Cada característica está implementada en `logic/IvanCruz_JuanOchoa_features.py`, expuesta mediante un transformador scikit-learn `LexicalFeaturizer` sin estado aprendido (por lo que no puede filtrar información del test), y validada con 20 pruebas unitarias sobre tweets reales del train identificados por `tweetid`.

La auditoría de Fase 0 sobre estas 9 características confirmó que ninguna es constante ni proxy de la longitud del texto (correlación máxima con el número de tokens: 0.117). La única sensible al preprocesamiento es `upper_ratio`, que pierde ~8 % de su señal si el texto se pasa a minúsculas antes de extraerla — condición documentada como requisito de uso: *el featurizer debe recibir texto crudo*.

3. Diseño experimental

- **Representación:** TF-IDF (uni + bigramas, `min_df=2`, `sublinear_tf=True`) unido a las características léxicas mediante `FeatureUnion`; vectorizador, escalador (`MinMaxScaler`) y sobremuestreo viven dentro de un `imblearn.Pipeline`, ajustados únicamente dentro de cada fold.
- **Validación cruzada:** `StratifiedKFold(n_splits=5, shuffle=True, random_state=42)`.
- **Balanceo:** `RandomOverSampler` dentro de cada fold, nunca antes de dividir train/validación.
- **Familias comparadas:** Naive Bayes multinomial, Regresión Logística, SVM lineal y Random Forest, sobre la representación unida, con macro-F1 medio en CV como criterio.
- **Test:** usado una sola vez, con el modelo ya elegido y ajustado sobre todo train; se reporta IC 95 % bootstrap (2000 réplicas) dado el tamaño reducido del test (506 tweets).

4. Resultados

Comparación de familias sobre la representación unida completa:

Familia	macro-F1 CV (media $\pm$ std)
Regresión Logística	0.398 $\pm$ 0.040
Naive Bayes multinomial	0.390 $\pm$ 0.021
SVM lineal	0.389 $\pm$ 0.027
Random Forest	0.363 $\pm$ 0.028

Ganó Regresión Logística ($C = 1.0$), coherente con la teoría: en un espacio TF-IDF disperso y de alta dimensión, los modelos lineales suelen superar a los árboles.

Evaluación final sobre test (una sola vez): $macro-F1 = 0.415$, $IC\ 95\ \% = [0.369, 0.458]$; $accuracy = 0.478$. Por clase:

Clase	Precision	Recall	F1
P	0.566	0.494	0.527
N	0.607	0.571	0.588
NEU	0.241	0.290	0.263
NONE	0.247	0.323	0.280

5. Ablación

Aporte marginal de cada configuración respecto a la unión sin las nuevas características ($macro-F1 = 0.390$):

Configuración	macro-F1 CV	Δ
Sin las nuevas	0.390	—
Con TODAS las nuevas	0.398	+0.008
Con nuevas SIN 'expresividad'	0.388	-0.010
Con nuevas SIN 'modificadores'	0.397	-0.001
Con nuevas SIN 'coloquial'	0.399	+0.001

El grupo expresividad es el único con señal medible (+0.010); los otros dos quedan dentro del ruido de la CV (± 0.035). Lo documentamos tal cual: con 1008 tweets el margen de mejora es pequeño, y aunque las 9 características cumplen el mínimo de la actividad, solo las 5 de expresividad aportan empíricamente sobre las 34 del taller.

6. Análisis de errores

De los 506 tweets de test, 264 (52.2 %) fueron mal clasificados. Sobre una muestra de 12, la categoría dominante (8 casos) corresponde a tweets sin señal de las features nuevas — dependen de contexto conversacional, referencias culturales o conocimiento de mundo que ninguna característica léxica puede capturar. Los otros 4 se dividen entre polaridad invertida, posiblemente por ironía (2) y otros patrones (2).

La matriz de confusión confirma el patrón: N y P se confunden entre sí con frecuencia, y NEU/NONE se dispersan hacia ambos polos porque las señales de expresividad se activan igual en un tweet neutro que en uno polarizado — el enfoque léxico distingue intensidad, no valencia por sí solo.

7. Limitaciones

- **Desbalance de clases:** persiste tras el sobremuestreo; NEU y NONE siguen siendo las peor predichas.
- **Ironía y sarcasmo:** ninguna característica del módulo la captura; es una causa principal de la confusión $P \leftrightarrow N$.

- **Dependencia dialectal:** la lista de regionalismos está sesgada hacia variedades que el corpus de España apenas representa (activación de solo 1.1 %); requeriría re-auditoría antes de usarse sobre InterTASS-PE o InterTASS-CR.
- **Tamaño del corpus:** 1008 tweets es poco para 4 clases desbalanceadas; la lección documentada es que aumentar la complejidad del modelo (más features, listas más largas, ensambles) empeora la generalización en este régimen, no la mejora.
- **Comparación con TASS 2018 oficial:** el rango publicado va de 0.383 a 0.503 sobre el test oficial de 1899 tweets con sistemas basados en embeddings. Nuestro 0.415 cae dentro de ese rango, pero la comparación no es directa (partición Dev, corpus de entrenamiento más pequeño, enfoque léxico sin preentrenamiento).

8. Conclusión

Las 9 características nuevas superan las tres pruebas de la auditoría de Fase 0, están documentadas con hipótesis lingüística explícita, vectorizadas dentro del módulo y validadas con tweets reales. El aporte empírico es modesto pero real (+0.008 en macro-F1 CV), concentrado en el grupo expresividad. El clasificador elegido, Regresión Logística, es coherente con la naturaleza dispersa y de alta dimensión de la representación unida. El protocolo experimental — CV estratificada, balanceo dentro del fold, test usado una sola vez, intervalo bootstrap — cumple los requisitos de la actividad y evita cualquier fuga de información.

Declaración de uso de IA

Para el desarrollo de esta actividad se utilizó Claude (Anthropic) como asistente en las siguientes tareas concretas:

- Redacción de la estructura inicial del módulo `IvanCruz_JuanOchoa_features.py`: esqueleto del dataclass `FeatureSpec`, plantilla del transformador `scikit-learn` `LexicalFeaturizer` y firmas de `extract_features / audit_features`.
- Generación de las listas semilla de intensificadores, atenuadores, interjecciones y regionalismos a partir de bibliografía estándar y observaciones lingüísticas generales sobre el español.
- Redacción de la plantilla de pruebas y de los casos de regresión a partir de los falsos positivos detectados al auditar el corpus real (siglas, “el Che”, “vaya” verbo, “medio” no atenuador).
- Redacción de la documentación `docs/caracteristicas_IvanCruz_JuanOchoa.md` y del notebook, a partir de los resultados ya obtenidos por los demás.
- Corrección de errores puntuales de código (manejo de `pandas` en la auditoría, compatibilidad con `imblearn.Pipeline`).

Todo lo que corresponde al análisis y a las decisiones técnicas del trabajo fue realizado por Ivan S. Cruz A. y Juan S. Ochoa V:

- Auditoría de las 9 características sobre el train real y decisión de mantenerlas o no.
- Selección del subconjunto final de 9 features y descarte explícito de las que solapaban con las de otros integrantes del equipo (risas, polaridad léxica, expletivos).
- Interpretación de la matriz de confusión y categorización manual de los 12 errores analizados.
- Lectura de la ablación por grupo y decisión de no añadir más features ante la evidencia de que el corpus no lo soporta.
- Verificación de que no hay fuga de información (todo dentro del `imblearn.Pipeline`, sin escalado ni selección fuera de los folds).
- Revisión y ajuste de cada cifra del notebook y del presente informe.

Toda cifra reportada aquí proviene de la ejecución real del notebook `notebooks/IvanCruz_JuanOchoa_features.ipynb` sobre los CSV de TASS facilitados por el docente. Las pruebas unitarias (`pytest tests/test_IvanCruz_JuanOchoa_features.py`) pasan en su totalidad en el entorno local del equipo.